



جامعة الإمام عبد الرحمن بن فيصل
IMAM ABDULRAHMAN BIN FAISAL UNIVERSITY

المملكة العربية السعودية
جامعة الإمام عبد الرحمن بن فيصل
كلية الدراسات التطبيقية وخدمة المجتمع
قسم نظم المعلومات الإدارية

الذكاء في الأعمال وتنقيب البيانات

تقرير مشروع Weka



Icon designed by [surang](#)

طلاب الشعبة 801

الاسم
احمد عبدالله البحار
محسن محمد النابود

المطلوب:

- المطلوب عمل تقرير يشرح فيه الطلبة مثال تطبيقي على استخدام برنامج Weka من خلال استخدام مجموعة من ال Datasets لتنفيذ 3 عمليات تنقيب وهي: 1: التصنيف 2: العنقدة 3: تحليل الارتباط وليس نوع واحد.
- المشروع يجب ان يشرح ال dataset وتفاصيلها ومن ثم عمل تنقيب في البيانات لاستخراج النتائج باستخدام التصنيف و العنقدة و تحليل الارتباط. وشرح هذه النتائج.
- المجموعة تتكون من طالبين كحد اقصى
- الدخول على الرابط التالي وتسجيل اسماء المجموعة

[groups.docx 801](#)

- درجة المشروع هي 10 درجات مقسمة كمايلي: درجتان على التنسيق, 8 درجات على المحتوى.
- لا يمكن استخدام ويكيبيديا كمصدر للمعلومات
- يجب ان يحتوي تقرير المشروع على الأقل على ما يلي:
- اسم المشروع وأسماء الطلاب وارقامهم الجامعية, المقدمة, مادة المشروع, الخلاصة, المصادر
- المشروع من 5 الى 10 صفحات كحد اقصى
- اخر موعد لاستلام المشروع هو الأسبوع الثالث عشر.
- يجب تحميل ملف التقرير لكل طالب في المجموعة بشكل فردي على البلاكبورد وعلى شكل MS World

- الاطلاع على الفيديو التالي وتحميل البرنامج:

https://youtu.be/r10yfCEG9Uc?list=PL86JZGzAEh4ud3JaPNvU3EFD_Z22peVSH

<https://www.youtube.com/watch?v=PW0cZB1ypIQ>

- هنا يوجد بعض ال dataset التي يشاع استخدامها في التدريب ويمكنكم استخدامها او البحث عن غيرها

<https://storm.cis.fordham.edu/~gweiss/data-mining/datasets.html>

فهرس المحتويات

المطلوب	2
مقدمة	3
مجموعة البيانات Dataset	4
التصنيف Classification	5
العنقدة Clustering	8
قواعد الارتباط Association Rules (قواعد الرابطة (الدعم والثقة ، خوارزمية Apriori ، 2022)	11
الخلاصة	13
المصادر	13

مقدمة

أثناء دراستنا لمقرر الذكاء في الأعمال وتنقيب البيانات، تعرفنا على أسس تنقيب البيانات وبعض من الخوارزميات الشهيرة في هذا المجال ومن هذا المنطلق حسب ما تم تكليفنا من قبل مدرس المقرر قمنا بالعمل على أحد أهم البرامج المعنية بتطبيق بعض خوارزميات تنقيب البيانات الا وهو برنامج Weka وسنستعرض في هذا التقرير بشكل مبسط كيفية استخدام هذا البرنامج لتطبيق الخوارزميات التالية:

- التصنيف: شجرة J48
- العنقدة: Simple K Means
- قواعد الارتباط: Apriori

مجموعة البيانات | Dataset

كما يظهر أدناه مجموعة بيانات المتعلقة بالطقس وحالة اللعب

```
@relation weather.symbolic

@attribute outlook {sunny, overcast, rainy}
@attribute temperature {hot, mild, cool}
@attribute humidity {high, normal}
@attribute windy {TRUE, FALSE}
@attribute play {yes, no}

@data
sunny,hot,high,FALSE,no
sunny,hot,high,TRUE,no
overcast,hot,high,FALSE,yes
rainy,mild,high,FALSE,yes
rainy,cool,normal,FALSE,yes
rainy,cool,normal,TRUE,no
overcast,cool,normal,TRUE,yes
sunny,mild,high,FALSE,no
sunny,cool,normal,FALSE,yes
rainy,mild,normal,FALSE,yes
sunny,mild,normal,TRUE,yes
overcast,mild,high,TRUE,yes
overcast,hot,normal,FALSE,yes
rainy,mild,high,TRUE,no
```

تتكون مجموعة البيانات من 5 خصائص:

Outlook, Temperature, Humidity, Windy, Play

1- Outlook: ويعني بها حالة الطقس وتحتل القيم التالية (مشمس، غائم،

ماطر)

2- Temperature: وهي درجة الحرارة وتتراوح قيمها ما بين (64-85)



3- Humidity: وهي الرطوبة وتتراوح بين (65-96)


4- Windy: وهي حالة الرياح إما (نعم، لا)

5- Play: وهي قرار اللعب إما (نعم، لا)

التصنيف | Classification

خطوات تطبيق التصنيف:





حيث قمنا بإجراء تصنيف للبيانات السابقة باستخدام خوارزميات الشجر Trees وبالتحديد شجرة (J48) كما قمنا باستخدام 50% من البيانات لتدريب الشجرة و50% للاختبار.

J48 pruned tree

```

-----
outlook = sunny
|  humidity = high: no (3.0)
|  humidity = normal: yes (2.0)
outlook = overcast: yes (4.0)
outlook = rainy
|  windy = TRUE: no (2.0)
|  windy = FALSE: yes (3.0)

```

Number of Leaves : 5

Size of the tree : 8

النتيجة | Result

تم تصنيف الشجرة إلى 3 فروع أساسية

اعتماداً على حالة الجو (Outlook)

وتم التفرع في حالة الجو المشمس بتصنيف

البيانات حسب درجة الرطوبة.

أما بالنسبة إلى الجو الغائم فإنه يتم اللعب في جميع الحالات.

وأخيراً بالنسبة للجو الماطر فإنه تم التفرع بتصنيف البيانات حسب ما إذا كان الهواء عاصف أم لا.

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0.800	1.000	0.667	0.800	0.727	-0.258	0.400	0.676	yes
	0.000	0.200	0.000	0.000	0.000	-0.258	0.400	0.286	no
Weighted Avg.	0.571	0.771	0.476	0.571	0.519	-0.258	0.400	0.565	

شرح بعض العناوين في نتيجة التصنيف (Saito & Rehmsmeier, 2015)

TP: معدل الإيجابيات الحقيقية (الحالات المصنفة بشكل صحيح كفئة معينة).

FP: معدل الإيجابيات الخاطئة (الحالات المصنفة خطأ كفئة معينة).

Precision: او الدقة هي نسبة الأمثلة الفعلية من فئة، مقسومة على إجمالي الأمثلة المصنفة على تلك الفئة.

Recall: نسبة الأمثلة المصنفة على أنها فئة معينة مقسومة على الإجمالي الفعلي في تلك الفئة (ما يعادل معدل TP).

F-Measure: مقياس مشترك ل Precision و Recall


$$F\text{-Measure} = 2 * Precision * Recall / (Precision + Recall)$$

MCC: يستخدم في التعلم الآلي كمقياس لجودة التصنيفات الثنائية (ذات الفئتين). يأخذ في الاعتبار الإيجابيات والسلبيات الصحيحة والخطأ، ويُنظر إليه عمومًا على أنه مقياس متوازن يمكن استخدامه حتى لو كانت الفئات ذات أحجام مختلفة جدًا.

ROC: (Receiver Operating Characteristics) قياس المساحة: من أهم القيم الناتجة عن Weka. يعطيك فكرة عن كيفية أداء المصنفات بشكل عام.



PRC: Area (Precision Recall) هو أكثر إفادة من ال ROC عند تقييم المصنفات الثنائية على مجموعات البيانات غير المتوازنة.

الرسم التوضيحي للشجرة:



العقدة | Clustering

خطوات تطبيق العقدة



```

Clusterer output

Number of iterations: 4
Within cluster sum of squared errors: 26.0

Initial starting points (random):

Cluster 0: rainy,mild,normal,FALSE,yes
Cluster 1: overcast,cool,normal,TRUE,yes

Missing values globally replaced with mean/mode

Final cluster centroids:

Attribute      Full Data      Cluster#
              (14.0)      (10.0)      (4.0)
=====
outlook        sunny        sunny        overcast
temperature    mild         mild         cool
humidity       high         high         normal
windy          FALSE        FALSE        TRUE
play           yes         yes         yes

Time taken to build model (full training data) : 0.01 seconds

=== Model and evaluation on training set ===

Clustered Instances

0      10 ( 71%)
1       4 ( 29%)

```

في حالة المقارنة يمكن الملاحظة ومعرفة

أن Cluster0:

الجو مشمس، درجة الحرارة معتدلة،

الرطوبة عالية، والهواء ليس عاصف، ويمكن اللعب.

وأن Cluster1:

الجو غائم، درجة الحرارة باردة،

الرطوبة طبيعية، الهواء عاصف، ويمكن اللعب.


وفي حالة الجمع بين جميع الحالات


نلاحظ بأن الأكثر احتمالاً هو أن:

الجو مشمس، درجة الحرارة معتدلة،

الرطوبة عالية، والهواء ليس عاصف، ويمكن اللعب.

بالنهاية نرى ان Cluster 0 مطابق للحالة العامة وهي الأكثر شيوعاً.





يمكن المقارنة بأي من الخصائص من خلال تمثيلها على محوري X,Y ومن خلال الرسم مثلنا Play على محور Y ونلاحظ عدد الذين يلعبون في Cluster0 أكثر من Cluster1.

قواعد الارتباط | Association Rules

(قواعد الرابطة (الدعم والثقة ، خوارزمية Apriori، 2022)

تُستخدم خوارزمية Apriori لتعدين مجموعات العناصر المتكررة واستنباط قواعد الارتباط من قاعدة بيانات المعاملات. كما أنها أول خوارزمية تعدين قواعد الارتباط

عدد الدعم: عدد المعاملات التي تحتوي على مجموعة صنف معين.

قواعد الرابطة: تعكس الترابط والترابط بين شيء وأمر أخرى. إذا كانت هناك علاقة معينة بين شيئين أو أكثر، فيمكن توقع أحدهما بواسطة أشياء أخرى.

تكون قاعدة الارتباط في شكل تعبير ضمني $X \Rightarrow Y$ ، حيث X و Y هما مجموعات فرعية منفصلة، أي (تقاطع X مع $Y = \emptyset$).

يمكن قياس قوة قاعدة الارتباط من خلال دعمها وثقتها.

الدعم (دعم): تحديد عدد المرات التي يمكن فيها استخدام القاعدة لمجموعة بيانات معينة.

$$s(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{N}$$

الثقة: حدد عدد مرات ظهور Y في المعاملات التي تتضمن X .

$$c(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)}$$

النتيجة

Weka Explorer

Preprocess Classify Cluster Associate Select attributes Visualize

Associator

Choose Apriori -N 10 -T 0 -C 0.9 -D 0.05 -U 1.0 -M 0.1 -S -1.0 -c -1

Start Stop

Result list (right-click for ...)

22:49:29 - Apriori

Associator output

```

=== Associator model (full training set) ===

Apriori
=====

Minimum support: 0.15 (2 instances)
Minimum metric <confidence>: 0.9
Number of cycles performed: 17

Generated sets of large itemsets:

Size of set of large itemsets L(1): 12

Size of set of large itemsets L(2): 47

Size of set of large itemsets L(3): 39

Size of set of large itemsets L(4): 6

Best rules found:

1. outlook=overcast 4 ==> play=yes 4    <conf:(1)> lift:(1.56) lev:(0.1) [1] conv:(1.43)
2. temperature=cool 4 ==> humidity=normal 4    <conf:(1)> lift:(2) lev:(0.14) [2] conv:(2)
3. humidity=normal windy=FALSE 4 ==> play=yes 4    <conf:(1)> lift:(1.56) lev:(0.1) [1] conv:(1.43)
4. outlook=sunny play=no 3 ==> humidity=high 3    <conf:(1)> lift:(2) lev:(0.11) [1] conv:(1.5)
5. outlook=sunny humidity=high 3 ==> play=no 3    <conf:(1)> lift:(2.8) lev:(0.14) [1] conv:(1.93)
6. outlook=rainy play=yes 3 ==> windy=FALSE 3    <conf:(1)> lift:(1.75) lev:(0.09) [1] conv:(1.29)
7. outlook=rainy windy=FALSE 3 ==> play=yes 3    <conf:(1)> lift:(1.56) lev:(0.08) [1] conv:(1.07)
8. temperature=cool play=yes 3 ==> humidity=normal 3    <conf:(1)> lift:(2) lev:(0.11) [1] conv:(1.5)
9. outlook=sunny temperature=hot 2 ==> humidity=high 2    <conf:(1)> lift:(2) lev:(0.07) [1] conv:(1)
10. temperature=hot play=no 2 ==> outlook=sunny 2    <conf:(1)> lift:(2.8) lev:(0.09) [1] conv:(1.29)

```

Status OK

Log x0

من خلال النتيجة حصلنا على نستطيع أن نرى قواعد الارتباط المتعلقة بقرار اللعب كالتالي:

- 1- في حال كان الجو مغيم فإن قرار اللعب سيكون نعم.
- 2- في حال كانت الرطوبة معتدلة والجو غير عاصف فإن قرار اللعب سيكون نعم.
- 3- في حال كان الجو مشمس والرطوبة مرتفعة فإن قرار اللعب سيكون لا.
- 4- في حال كان الجو ماطر وليس عاصف فإن قرار اللعب سيكون لا.

كما يظهر لنا أن الدعم = 15% والثقة 90%.

الخلاصة

بعد أن طبقنا الخوارزميات السابقة في برنامج "ويكا" نرى أهميتها في تنقيب البيانات فمنها نرى كيف تم تصنيف البيانات من خلال خوارزمية شجرة J48 كما تم توضيحه بالرسم، كيفية توزيع عناقيد البيانات من خلال خوارزمية Simple K Means، وأخيراً الارتباطات بين البيانات التي تم العثور عليها عن طريق خوارزمية Apriori. لذلك برنامج ويكا يعد أداة فعالة لتطبيق مفاهيم تنقيب البيانات وبالتحديد الخوارزميات المستخدمة فيها.

المصادر

Saito Takaya، و Marc Rehmsmeier. (March, 2015 4). *The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets*. تم الاسترداد من PubMed Central: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4349800>

قواعد الرابطة (الدعم والثقة ، خوارزمية Apriori). (May, 2022 18). تم الاسترداد من المبرمج العربي: arabic programmer: [/https://arabicprogrammer.com/article/47301905600](https://arabicprogrammer.com/article/47301905600)